

# 1. 在 `ex2_logistic_original.ipynb` 中训练 Logistic 模型并调试超参数

## 1.1 训练涉及的超参数

本实验中调试的核心超参数如下：

- `max_iter = 10`
- `batch_size = 8`
- `learning_rate = 0.2`

## 1.2 参数与训练表现分析

### 1. 训练速度特征

- 小批量训练下，单次更新较快
- 在 CPU 环境中可稳定运行

### 2. 结果现象

- 损失曲线整体下降，说明模型在收敛
- 准确率曲线整体上升，说明训练有效
- 后期曲线趋于平稳，继续增加迭代的收益会变小

### 3. 参数变化趋势


- `learning_rate` 过小：收敛更稳定但训练时间增加
- `learning_rate` 过大：收敛更快但可能出现振荡
- `batch_size` 更小：更新更频繁，通常更慢、波动更大
- `max_iter` 增大：时间近似线性增加，效果提升逐步减弱

## 1.3 程序输出结果


训练日志截图：

```
Size of training set: 48830
Size of testing set: 5426
Dimension of data: 510
Training loss: 0.271355435246406
Training accuracy: 0.8836166291214418
```

Loss 与 Accuracy 曲线：



Logistic PR 曲线:



## 2. 在 `ex2_logistic_xgboost.ipynb` 中完成多模型对比与问答

### 2.1 四种模型 PR 曲线与结果对比


本次运行输出如下：

| 模型                  | AP            | 训练时间        | 结论            |
|---------------------|---------------|-------------|---------------|
| Logistic Regression | <b>0.6877</b> | 1.68        | AP 最好，综合表现最佳  |
| Decision Tree       | 0.5787        | <b>1.14</b> | 训练最快，但精度最低    |
| Random Forest       | 0.6564        | 14.29       | AP 次优，但耗时明显更高 |

结论分析：

- AP 排名： `Logistic > Random Forest > Decision Tree`
- 时间成本： `Decision Tree < Logistic << Random Forest`
- 在当前特征工程与参数设置下，Logistic 的精度-效率平衡最好。

PR 对比图如下：



## 2.2 采用了哪种特征工程？原理、实现过程、影响

本实验特征工程流程为：方差筛选 + 标准化 + PCA。

### 1. 方差筛选

- 原理：删除方差过低、区分能力弱的特征
- 实现：`varianceThreshold(threshold=0.1)`

### 2. 标准化

- 原理：统一量纲，避免某些特征数值过大主导训练
- 实现：`fit_transform / transform`，并对极端值进行 `np.clip(-10, 10)`

### 3. PCA 降维

- 原理：在保留主要信息的前提下降低维度，减少冗余特征
- 实现：根据维度动态设置主成分数，本次最终降到 30 维

## 本次运行的量化结果

| 处理阶段      | 特征维度 | 备注                                    |
|-----------|------|---------------------------------------|
| 原始数据      | 510  | X shape: (54256, 510)                 |
| 方差筛选后     | 53   | After variance filtering: 53 features |
| PCA 后     | 30   | After PCA: 30 features                |
| PCA 解释方差比 | 0.99 | Explained variance ratio sum: 0.99    |

影响分析：

- 从 510 维降到 30 维，压缩比例高，训练更高效
  - 同时保留 99% 方差信息，说明信息损失较小
  - 这也是 Logistic 在 AP 上取得最好结果的重要原因之一
- 

## 2.3 简述正则化的作用，以及对模型影响

正则化通过对参数加惩罚项来限制参数过大，核心目标是抑制过拟合、提高泛化能力。

- L1 正则：可产生稀疏权重，有特征选择效果
- L2 正则：让参数更平滑，训练更稳定

对模型影响：

- 训练集指标可能略降
  - 测试集稳定性通常更好
  - PR 曲线在验证/测试集上更可靠
- 

## 2.4 XGBoost 相对于 Logistic 的优势

XGBoost 相对 Logistic 的优势：

- 能建模非线性关系与特征交互
- Boosting 框架通常有更高精度上限
- 自带正则化与采样机制，泛化能力强

代价：

- 参数更多，调参复杂
- 训练时间更高
- 可解释性通常弱于 Logistic